# Поиск дубликатов

# **Python**

# Приведение строки к нижнему регистру

In string.lower()

#### Подсчёт различных значений в списке

```
In from collections import Counter

Counter(lst)

# используется коллекция Counter,
# реализующая словарь для подсчёта
# колличества неизменяемых объектов
```

# **Pandas**

### Приведение строк в колонке к нижнему регистру

In data['column'].str.lower()

## **NLTK**

#### Получение стеммера для русского языка

## Получение стема от слова на русском

In russian\_stemmer.stem(word)

# **PyMystem**

## Получение стеммера/лемматизатора для слов на русском

```
from pymystem3 import Mystem
m = Mystem()
```

## Лемматизация строки с русским текстом

In m.lemmatize(text)

# Словарь

#### Стемминг

процесс нахождения стема (основы слова)

#### Лемматизированное слово

слово, сведённое к лемме

#### Лемматизация

приведение слова к лемме (его словарной форме):

- *для существительных* именительный падеж, единственное число;
- для прилагательных именительный падеж, единственное число, мужской род;
- для глаголов, причастий, деепричастий глагол в инфинитиве несовершенного вида.